


Laporan Analisis Variational Autoencoder (VAE) pada Fashion-MNIST

Mata Kuliah Pembelajaran Mesin 2

Dosen Pengampu :

Dr. Oddy Virgantara Putra, S.Kom., M.T.



Disusun Oleh:

Nama: Mutiara Afny Imro'atus Sholihah

NIM: 442023618080

Tanggal: 1 September 2025

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS DARUSSALAM GONTOR KAMPUS MANTINGAN

2025//1447

Model Variational Autoencoder (VAE) yang kita bangun adalah salah satu jenis model generatif yang kuat. Berbeda dengan Autoencoder tradisional yang hanya belajar kompresi data, VAE menambahkan pendekatan probabilistik untuk memastikan representasi latennya terdistribusi dengan baik, menjadikannya ideal untuk menghasilkan data baru.

Keputusan Teknis dan Arsitektur Model

Dalam arsitektur model ini, setiap keputusan teknis dibuat dengan alasan yang jelas:

- **Encoder:** Bertugas memampatkan gambar input 28×28 piksel ke dalam ruang laten 2 dimensi. Kami menggunakan tiga lapisan konvolusi (Conv2D) dengan $\text{strides}=(2, 2)$ pada lapisan kedua dan ketiga untuk secara efisien mengurangi dimensi spasial dari gambar ($28 \times 28 \rightarrow 14 \times 14 \rightarrow 7 \times 7$). Keputusan ini memungkinkan model mengekstrak fitur-fitur hierarkis dari gambar. Encoder tidak memetakan gambar ke satu titik, tetapi ke parameter distribusi normal—yaitu, z_{mean} (rata-rata) dan $z_{\text{log_var}}$ (\log -variansi). Ini adalah inti dari "variational" pada VAE.
- **Trik Reparameterisasi:** Ini adalah keputusan teknis paling krusial. Karena kita tidak dapat melakukan *backpropagation* melalui proses sampling acak, kita menggunakan trik reparameterisasi. Rumusnya $z = z_{\text{mean}} + \epsilon \cdot \sqrt{e^{0.5 \cdot z_{\text{log_var}}}}$, di mana ϵ adalah variabel acak dari distribusi normal standar. Dengan cara ini, gradien dapat mengalir melalui z_{mean} dan $z_{\text{log_var}}$, memungkinkan model untuk belajar parameter distribusi laten.
- **Decoder:** Bertugas merekonstruksi gambar dari ruang laten. Kami menggunakan lapisan Conv2DTranspose untuk melakukan *upsampling* yang merupakan kebalikan dari proses konvolusi. Lapisan-lapisan ini secara efektif mengubah vektor laten dimensi rendah menjadi gambar berdimensi tinggi ($2 \rightarrow 7 \times 7 \rightarrow 14 \times 14 \rightarrow 28 \times 28$). Aktivasi sigmoid pada lapisan output dipilih karena output piksel gambar berada dalam rentang $[0,1]$, cocok dengan data yang telah dinormalisasi.

Pembahasan Kritis Terhadap Hasil

Hasil dari *notebook* ini memberikan wawasan yang mendalam dan memuaskan tentang cara kerja VAE:

- **Loss dan Pelatihan:** Penurunan progresif pada nilai `loss` dan `val_loss` menunjukkan bahwa model tidak hanya belajar dari data pelatihan, tetapi juga mampu menggeneralisasi dengan baik pada data validasi. `kl_loss` yang juga menurun menandakan model berhasil mendorong distribusi laten mendekati distribusi normal standar, memastikan ruang laten terstruktur dengan baik.
- **Analisis Rekonstruksi:** Gambar-gambar yang direkonstruksi menunjukkan model berhasil menangkap fitur-fitur penting. Meskipun hasilnya tidak sempurna dan sedikit buram, ini adalah hal yang wajar. VAE mengorbankan sedikit akurasi rekonstruksi demi belajar ruang laten yang kontinu dan teratur.
- **Visualisasi Ruang Laten:** Plot t-SNE menunjukkan kluster-kluster (kelompok) yang terpisah dengan baik untuk setiap jenis pakaian. Ini adalah bukti paling kuat bahwa VAE kita berhasil. Pengelompokan ini menunjukkan bahwa model telah belajar representasi

yang bermakna; ia memahami perbedaan antara sepatu dan kaos, dan mengorganisasinya dalam ruang laten. Ini adalah konsekuensi langsung dari peran `kl_loss` dalam mendorong organisasi ini.

- **Generasi Gambar dan Interpolasi:** Kemampuan model untuk menghasilkan gambar-gambar baru dari vektor acak di ruang laten membuktikan bahwa decoder kita berfungsi sebagai generator yang efektif. Lebih menarik lagi, interpolasi di ruang laten menghasilkan transisi yang mulus antara gambar-gambar yang berbeda. Misalnya, transisi dari kaos ke jaket akan melalui serangkaian gambar hibrida. Hal ini menegaskan bahwa ruang laten bersifat *kontinu* dan tidak memiliki "lubang" atau celah, menjadikannya ideal untuk eksplorasi dan generasi kreatif.

Refleksi Jujur dan Pembelajaran

Proses membangun dan menyempurnakan kode ini adalah pengalaman yang berharga. Secara jujur, saya juga menggunakan bantuan AI Gemini dalam perjalanan ini. Gemini membantu saya memahami konsep-konsep kompleks dan menyusun struktur kode yang efisien.

Ada satu pelajaran penting yang saya dapatkan dari kegagalan yang lalu, yaitu ketika kita mencoba melakukan interpolasi dan mendapatkan kesalahan `ValueError`. Kegagalan tersebut terjadi karena ketidakcocokan bentuk (`shape`) data. Saya belajar bahwa pemahaman detail teknis, seperti bagaimana `numpy.linspace` berinteraksi dengan dimensi array, sangat penting. Kesalahan kecil dalam bentuk data dapat menghentikan seluruh proses, tidak peduli seberapa canggih arsitektur modelnya.

Keseluruhan proses ini mengajarkan saya bahwa pengembangan model *deep learning* adalah proses yang iteratif, penuh dengan *debugging*, dan menuntut pemahaman mendalam pada setiap komponennya.